

Trabajo Práctico 1

Clustering espectral de países según sus gustos musicales en
Spotify

Integrantes

Max Lastra
Benjamín Nuñez

Base de datos: *Top Spotify Songs in 73 Countries (Daily Updated)* (Kaggle),
Top 50 diario de 72 países, 18-10-2023 a 11-06-2025.

Índice

1. Introducción	2
2. Desarrollo (Parte I)	2
2.1. Pregunta 1. Una red como objeto matricial	2
2.2. Pregunta 2. La forma cuadrática del Laplaciano	2
2.3. Pregunta 3. Matriz de incidencia y SVD	3
2.4. Pregunta 4. El espectro y la conectividad	3
2.5. Pregunta 5. Partición como problema de optimización	4
2.6. Pregunta 6. Clustering espectral con k grupos	4
3. Aplicación	5
3.1. Problema y datos	5
3.2. Construcción y preparación de la red	5
3.3. Implementación del método espectral	6
3.4. Resultados e interpretación	7
3.5. Diseño experimental	10
3.6. Limitaciones y extensiones	12
4. Conclusiones	12
Referencias	13
Declaración de uso de Inteligencia Artificial	13

1. Introducción

En Ciencia de Datos, el clustering busca separar elementos en grupos parecidos por dentro y distintos entre sí. Cuando los datos forman una red, como personas que se comunican o países que escuchan la misma música, esos grupos son comunidades: nodos muy conectados entre sí y poco conectados con el resto. El clustering espectral las encuentra con álgebra lineal: representa la red con las matrices A , D y el Laplaciano $L = D - A$, y usa los vectores propios de L de menor valor propio como coordenadas de cada nodo, de forma parecida a como PCA usa vectores propios para resumir datos. En esas coordenadas los grupos quedan separados y k -means los encuentra con facilidad.

La relación entre el espectro del Laplaciano y la conectividad de un grafo se estudia desde los años 70, y el método se popularizó a comienzos de los 2000 para segmentar imágenes; hoy también se usa en redes sociales y en biología. Su ventaja es que solo necesita similitudes entre pares de elementos, detecta grupos de formas no convexas y el propio espectro indica cuántas componentes y cuántos grupos hay; su desventaja es que depende de cómo se construye la red, exige elegir el número de grupos y es costoso en redes muy grandes. Representar la red con matrices es útil porque propiedades globales, como sus partes desconectadas o su punto más débil, aparecen en los valores y vectores propios de L .

2. Desarrollo (Parte I)

En esta sección, $G = (V, E)$ es un grafo no dirigido y ponderado con n nodos, pesos $a_{ij} = a_{ji} \geq 0$ y $a_{ii} = 0$. Además, $d_i = \sum_j a_{ij}$, $D = \text{diag}(d_1, \dots, d_n)$ y $L = D - A$.

2.1. Pregunta 1. Una red como objeto matricial

(a) A indica qué nodos están conectados y con qué peso. D indica cuánta conexión total tiene cada nodo (su grado). $L = D - A$ combina ambas y, como se ve en la Pregunta 2, mide cuánto cambia una función al recorrer las aristas.

(b) Un vector $x \in \mathbb{R}^n$ se interpreta como la función que asigna el número x_i al nodo i . Por ejemplo, x_i puede ser el grado del nodo i , o $x_i = 1$ si el nodo pertenece a cierto grupo y 0 si no.

(c) El conjunto $\mathcal{F}(V) = \{f : V \rightarrow \mathbb{R}\}$, con suma $(f + g)(v) = f(v) + g(v)$ y producto por escalar $(\alpha f)(v) = \alpha f(v)$, es un espacio vectorial. Las operaciones dan otra función sobre los nodos, y los axiomas se cumplen porque se cumplen en $\mathbb{R}$ evaluando en cada nodo. El neutro es la función nula y el inverso de f es $-f$. Las funciones indicadoras de cada nodo forman una base, así que $\mathcal{F}(V) \cong \mathbb{R}^n$.

Ejemplo. Con tres nodos, sean $f = (0, 5; 0, 8; 0)$ y $g = (1; 1; 0)$ dos funciones sobre ellos. Entonces $f + g = (1, 5; 1, 8; 0)$ y $2f - 3g = (-2; -1, 4; 0)$.

(d) Si la red es no dirigida, $a_{ij} = a_{ji}$, es decir, $A^\top = A$. Como D es diagonal, $D^\top = D$. Luego $L^\top = D^\top - A^\top = D - A = L$.

2.2. Pregunta 2. La forma cuadrática del Laplaciano

Demostración de la identidad. Por un lado, $x^\top Lx = x^\top Dx - x^\top Ax = \sum_{i,j} a_{ij}x_i^2 - \sum_{i,j} a_{ij}x_i x_j$, usando que $d_i = \sum_j a_{ij}$. Por otro lado,

$$\frac{1}{2} \sum_{i,j} a_{ij} (x_i - x_j)^2 = \frac{1}{2} \sum_{i,j} a_{ij} x_i^2 + \frac{1}{2} \sum_{i,j} a_{ij} x_j^2 - \sum_{i,j} a_{ij} x_i x_j.$$

Por simetría de A , las dos primeras sumas son iguales, y juntas valen $\sum_{i,j} a_{ij}x_i^2$. Por lo tanto ambas expresiones coinciden.

(a) Cada término $a_{ij}(x_i - x_j)^2$ es mayor o igual a 0, luego $x^\top Lx \geq 0$ para todo x : L es semidefinida positiva.

(b) $x^\top Lx$ suma, sobre todas las aristas, el peso de la arista por el cuadrado de la diferencia entre los valores de sus extremos. Mide la *variación* de la función x sobre la red: es pequeña si x cambia poco entre nodos conectados.

(c) Si los nodos fuertemente conectados (con a_{ij} grande) reciben valores similares, sus términos son casi nulos y $x^\top Lx$ es pequeña. Por eso, las funciones que minimizan $x^\top Lx$ son casi constantes dentro de los grupos densos.

(d) $(L\mathbf{1})_i = d_i - \sum_j a_{ij} = 0$, luego $L\mathbf{1} = 0$. El vector constante no varía en ninguna arista, así que es un vector propio de valor propio 0, que es el menor posible porque L es semidefinida positiva. Ese vector no distingue grupos.

2.3. Pregunta 3. Matriz de incidencia y SVD

Se orienta cada arista $e = \{i, j\}$ de i a j y se define $B \in \mathbb{R}^{m \times n}$ con $B_{ei} = 1$, $B_{ej} = -1$ y 0 en el resto. Así, $(Bx)_e = x_i - x_j$.

(a) $(B^\top B)_{kl} = \sum_e B_{ek} B_{el}$. Si $k = l$, la suma cuenta las aristas que tocan a k , es decir, d_k . Si $k \neq l$, solo aporta la arista entre k y l (si existe), con producto $1 \cdot (-1) = -1$, es decir, $-a_{kl}$. Luego $B^\top B = D - A = L$.

(b) Con pesos, la fila de cada arista se multiplica por $\sqrt{w_e}$ ($\tilde{B} = W^{1/2}B$). Repitiendo el cálculo, $\tilde{B}^\top \tilde{B} = B^\top W B = L$.

(c) Si $B = U\Sigma V^\top$, entonces $L = B^\top B = V\Sigma^\top U^\top U\Sigma V^\top = V\Sigma^\top \Sigma V^\top$, porque $U^\top U = I$.

(d) $\Sigma^\top \Sigma$ es diagonal con entradas σ_i^2 , así que $L = V(\Sigma^\top \Sigma)V^\top$ es una diagonalización ortogonal de L . Por lo tanto, los valores propios de L son los cuadrados de los valores singulares de B ($\lambda_i = \sigma_i^2$), y los vectores propios de L son los vectores singulares derechos de B (columnas de V).

2.4. Pregunta 4. El espectro y la conectividad

(a) L es real y simétrica. Por el teorema espectral, $L = Q\Lambda Q^\top$ con Q ortogonal, y las columnas de Q forman una base ortonormal de $\mathbb{R}^n$ de vectores propios de L .

(b) Sean $C_1, \dots, C_k$ las componentes conexas y $\mathbf{1}_{C_r}$ sus vectores indicadores. Si $i \in C_r$, entonces $(L\mathbf{1}_{C_r})_i = d_i - \sum_{j \in C_r} a_{ij} = 0$, porque todos los vecinos de i están en C_r . Si $i \notin C_r$, entonces $(L\mathbf{1}_{C_r})_i = -\sum_{j \in C_r} a_{ij} = 0$, porque no hay aristas entre componentes. Luego los k vectores $\mathbf{1}_{C_r}$ están en $\ker L$. Como tienen soportes disjuntos, son linealmente independientes.

(c) Si $Lx = 0$, entonces $x^\top Lx = 0$, y por la Pregunta 2, $x_i = x_j$ en cada arista. Así x es constante en cada componente, es decir, $x \in \text{span}\{\mathbf{1}_{C_r}\}$. Por lo tanto, la multiplicidad del valor propio 0 es igual al número de componentes conexas.

(d) Si $\lambda_2 = 0$, la red está desconectada. Si λ_2 es positivo pero pequeño, es conexa pero se puede separar cortando pocas aristas o aristas débiles. Si λ_2 es relativamente grande, la red está bien conectada y no tiene un corte barato.

(e) El vector de Fiedler minimiza $x^\top Lx$ entre los vectores unitarios ortogonales a $\mathbf{1}$ (Pregunta 5f). Al ser ortogonal a $\mathbf{1}$, debe tener coordenadas positivas y negativas. Al minimizar la variación, asigna valores parecidos a nodos muy conectados. Por eso cambia de signo justamente donde

hay pocas conexiones, y su signo sugiere una separación de la red.

2.5. Pregunta 5. Partición como problema de optimización

(a) Una partición $V = S \cup \bar{S}$ se representa con $s \in \{-1, 1\}^n$, donde $s_i = 1$ si $i \in S$ y $s_i = -1$ si $i \in \bar{S}$.

(b) $\text{cut}(S, \bar{S}) = \sum_{i \in S, j \in \bar{S}} a_{ij}$. Como $(s_i - s_j)^2$ vale 4 si i y j están en grupos distintos y 0 si no, se tiene $\text{cut}(S, \bar{S}) = \frac{1}{4} s^\top L s$.

(c) El corte no considera el tamaño de los grupos. Separar un solo nodo de grado bajo cuesta muy poco, por lo que el mínimo tiende a aislar nodos periféricos.

(d) Los criterios balanceados dividen el corte por el tamaño de cada grupo:

$$\text{RatioCut} = \frac{\text{cut}(S, \bar{S})}{|S|} + \frac{\text{cut}(S, \bar{S})}{|\bar{S}|}, \quad \text{NCut} = \frac{\text{cut}(S, \bar{S})}{\text{vol}(S)} + \frac{\text{cut}(S, \bar{S})}{\text{vol}(\bar{S})}, \quad \text{vol}(S) = \sum_{i \in S} d_i.$$

Ambos se hacen grandes si un grupo es muy pequeño. RatioCut equilibra el número de nodos y NCut equilibra la suma de grados.

(e) Para RatioCut se define $f_i = \sqrt{|\bar{S}|/|S|}$ si $i \in S$ y $f_i = -\sqrt{|S|/|\bar{S}|}$ si $i \in \bar{S}$. Se verifica que $f^\top L f = n \cdot \text{RatioCut}(S, \bar{S})$, que $\sum_i f_i = 0$ y que $\|f\|^2 = n$. Minimizar RatioCut equivale entonces a minimizar $f^\top L f$ sobre esos vectores discretos. La relajación permite que f sea cualquier vector de $\mathbb{R}^n$ con $f \perp \mathbf{1}$ y $\|f\| = \sqrt{n}$, y así se obtiene la minimización de una forma cuadrática del Laplaciano. Con NCut se llega de la misma forma al Laplaciano normalizado $L_{\text{sym}} = I - D^{-1/2} A D^{-1/2}$.

(f) Sea $q_1 = \mathbf{1}/\sqrt{n}, q_2, \dots, q_n$ una base ortonormal de vectores propios con $0 = \lambda_1 \leq \lambda_2 \leq \dots$. Si $x = \sum_i c_i q_i$, las restricciones dan $c_1 = 0$ y $\sum_i c_i^2 = 1$. Luego

$$x^\top L x = \sum_{i \geq 2} \lambda_i c_i^2 \geq \lambda_2 \sum_{i \geq 2} c_i^2 = \lambda_2,$$

y la igualdad se alcanza con $x = q_2$. La solución es el vector propio del segundo menor valor propio.

(g) Para obtener una partición a partir de la solución continua v_2 , se asigna cada nodo según el signo de su coordenada: $S = \{i : v_2(i) \geq 0\}$. Otra opción es ordenar los nodos por v_2 y elegir el umbral que minimiza NCut.

2.6. Pregunta 6. Clustering espectral con k grupos

Sea $U = [v_1 \cdots v_k]$ la matriz con los k vectores propios de menor valor propio.

(a-b) La fila i de U contiene los valores de las k funciones más suaves de la red en el nodo i . Así, cada nodo queda representado como un punto de $\mathbb{R}^k$. Si la red tuviera k componentes, todos los nodos de una misma componente caerían en el mismo punto.

(c) En esta representación, los nodos muy conectados entre sí quedan cerca, porque los vectores propios varían poco entre ellos. La distancia euclidiana entre filas mide entonces qué tan probable es que dos nodos estén en la misma comunidad.

(d) Se aplica k -means a las filas de U y cada nodo se asigna al grupo de su fila. Con L_{sym} , antes se normaliza cada fila a norma 1.

(e) Las características originales tienen dimensión muy alta y no usan la estructura de red. Las filas de A solo contienen información local, es decir, los vecinos directos. La representación

espectral tiene dimensión k y resume la estructura global de la red, por lo que los grupos quedan compactos y separados.

(f) Si hay k grupos bien separados, $\lambda_1, \dots, \lambda_k$ son casi 0 y λ_{k+1} es claramente mayor. Por eso se elige el k con el mayor salto $\lambda_{k+1} - \lambda_k$ (*eigengap*).

(g) Dos situaciones problemáticas:

- Con grados muy distintos, el Laplaciano no normalizado separa nodos sueltos de grado bajo.
- Si no hay un salto claro en los valores propios, la elección de k es ambigua, y si dos valores propios son casi iguales, los vectores propios (y la partición) se vuelven inestables.

3. Aplicación

3.1. Problema y datos

Fuente. *Top Spotify Songs in 73 Countries (Daily Updated)*, publicado en Kaggle con licencia ODC-By. Contiene el Top 50 diario de Spotify de cada país. Se usó todo el período disponible: del 18-10-2023 al 11-06-2025, es decir, 583 días y 2.110.316 filas. El notebook descarga los datos automáticamente.

La red.

- Nodos: los 72 países con ranking propio. Se excluye el Top 50 Global, que no es un país.
- Aristas: unen cada país con sus 12 países de gustos más parecidos.
- Pesos: la similitud coseno entre sus perfiles musicales.
- Dirección: la red es no dirigida y tiene 665 aristas.

Pregunta de análisis. *¿Cómo se agrupan los países según lo que escuchan en Spotify, y qué explica mejor esos grupos: el idioma, la geografía o el clima? ¿Qué rol cumplen los éxitos globales?*
Subpreguntas:

1. ¿Cuántos grupos sugiere el espectro?
2. ¿Las comunidades coinciden más con idioma, continente o clima?
3. ¿Qué cambia al quitar los éxitos globales?
4. ¿Con quién se agrupa Chile y qué países son puente?

Por qué clustering espectral. Cada país tiene un perfil de más de 23 mil canciones, y como casi todos comparten los éxitos globales, agrupar esos perfiles directamente separa mal a los países. Es más natural representarlos como una red de similitudes y buscar comunidades en ella. El clustering espectral hace eso: el espectro del Laplaciano indica si la red se separa en bloques y cuántos grupos sugiere (*eigengap*), sin fijar ese número de antemano, y sus vectores propios entregan una representación de pocas dimensiones donde los grupos quedan separados.

3.2. Construcción y preparación de la red

Decisiones de preprocesamiento.

- Se excluyó el Top 50 Global.
- Se conservaron las posiciones ≤ 50 y se eliminaron 90 filas duplicadas.
- Cada canción se identificó por *nombre + artistas*, porque una misma canción puede tener varios identificadores según el mercado. Así quedan 23.021 canciones, contra 24.977 identificadores.

Perfiles y similitud. Cada país c se representa con el vector x_c , donde $x_c(s)$ es el número de días que la canción s estuvo en su Top 50. La similitud entre dos países es el coseno $s_{ij} = \langle x_i, x_j \rangle / (\|x_i\| \|x_j\|)$. El coseno compara proporciones, así que no importa que algunos países tengan menos días de datos (Reino Unido tiene 418).

Construcción de la red. Casi todos los países comparten algún éxito global, así que conectar a todos con todos diluye la estructura. Se conectó cada país con sus k más parecidos y se simetrizó la red. Esto garantiza que no haya nodos aislados y que no haya *loops*.

Elección de k y componentes conexas. Se eligió el menor k que deja la red conexas, que resultó ser $k = 12$. Para $k \leq 11$ la red tiene dos componentes: los 17 países hispanohablantes de América Latina más España, y el resto del mundo (Figura 1). Es decir, ningún país hispano tiene a un país no hispano entre sus 11 más parecidos. En ese caso el valor propio 0 es doble, como predice la Pregunta 4c.



Figura 1: Número de componentes conexas según el número de vecinos k .

Atributos para evaluar. Para cada país se registró su continente, su idioma principal y su clima. El clima se definió según dónde vive la población: a cada ciudad de más de 15.000 habitantes (GeoNames) se le asignó su clase climática Köppen-Geiger 1991–2020 y su temperatura media (WorldClim), y se calculó la proporción de población urbana en cada grupo (Tropical, Seco, Templado, Continental o Polar). Un país es “Variado” solo si es imposible encasillarlo: ningún grupo reúne al menos el 60 % de la población y la temperatura varía en $\pm 3^\circ\text{C}$ o más entre sus ciudades. Así, EE.UU. (53 % templado, $\pm 4,6^\circ\text{C}$) queda Variado y Brasil (63 % tropical) queda Tropical. Los países variados son EE.UU., México, Bolivia, Ecuador y Guatemala.

3.3. Implementación del método espectral

El notebook `clustering_espectral_spotify.ipynb` implementa con `numpy`:

1. la construcción de A , $D = \text{diag}(A\mathbf{1})$, $L = D - A$ y $L_{\text{sym}} = I - D^{-1/2}AD^{-1/2}$;
2. el cálculo de valores y vectores propios con `numpy.linalg.eigh`;

- la representación espectral: los k primeros vectores propios de L_{sym} , con cada fila normalizada a norma 1;
- k -means de `scikit-learn` (50 inicializaciones, semilla fija).

Se usa L_{sym} porque los grados son muy heterogéneos: van de 0,07 (Nigeria) a 15,2 (Suiza).

3.4. Resultados e interpretación

Espectro y eigengap. Los primeros valores propios de L_{sym} son 0; 0,0003; 0,313; 0,384; 0,661; ... El mayor salto ocurre después de λ_2 y el segundo después de λ_4 (Figura 2). Por eso se analizan $k = 2$ y $k = 4$. Además, $\lambda_2 \approx 0$: la red es conexa, pero está casi separada en dos bloques.




Figura 2: Valores propios de L_{sym} y eigengap. Los saltos más grandes ocurren tras $k = 2$ y tras $k = 4$.

Vector de Fiedler. Su signo separa exactamente a los 18 países hispanos del resto (Figura 3). Como λ_2 es casi cero, el vector es prácticamente constante dentro de cada bloque.




Figura 3: Vector de Fiedler ordenado, coloreado por continente.

Comunidades. Con $k = 2$ se obtienen el bloque hispano (18 países) y el resto del mundo (54). Con $k = 4$ (Figura 4):

- Hispano (18): América Latina hispanohablante y España.

- Europa y mundo anglosajón (33): Europa occidental, nórdica, central y báltica, EE.UU., Canadá, Australia, Nueva Zelanda, Sudáfrica, Nigeria, Israel, Turquía y Brasil.
- Asia, Medio Oriente y Europa del Este (19).
- Sur de Asia (2): India y Pakistán.

La Figura 5 muestra la representación espectral: los 18 países hispanos caen prácticamente en un mismo punto.

Comunidades de gusto musical ($k = 4$)




Figura 4: Comunidades obtenidas con clustering espectral ($k = 4$).




Figura 5: Representación espectral de los países ($k = 4$), proyectada a dos dimensiones.

En la red (Figura 6), la única arista entre el bloque hispano y el resto es Japón–Perú, con similitud 0,034. Se explica casi por completo por canciones de K-pop que estuvieron muchos días en el Top 50 de ambos países, como *Who* de Jimin y *Seven* de Jung Kook.

Red de países (12 vecinos), coloreada por comunidad




Figura 6: Red de países (12 vecinos), coloreada por comunidad. La arista destacada es la única entre bloques.

¿Idioma, geografía o clima? Se compararon las comunidades con cada atributo mediante el AMI (información mutua ajustada), que vale 0 para una partición al azar y 1 para una coincidencia perfecta (Tabla 1). El continente es el atributo que más coincide, seguido por el idioma, y el clima es el que menos explica. Igualmente, el idioma explica casos que la geografía no explica: España se agrupa con América Latina y no con Europa, y Brasil no se agrupa con sus vecinos hispanohablantes.

El AMI se calcula a partir de la información mutua entre la partición en comunidades U y la categoría V :

$$\text{AMI}(U, V) = \frac{\text{MI}(U, V) - E[\text{MI}]}{\frac{1}{2}(H(U) + H(V)) - E[\text{MI}]},$$

$$\text{MI}(U, V) = \sum_{i,j} \frac{n_{ij}}{n} \log \frac{n_{ij}}{a_i b_j}, \quad H(U) = - \sum_i \frac{a_i}{n} \log \frac{a_i}{n},$$

donde n es el número de países, n_{ij} el número de países que están en la comunidad i y en la categoría j , a_i y b_j los tamaños de la comunidad y de la categoría, y $E[\text{MI}]$ la información mutua esperada si los países se repartieran al azar entre grupos de los mismos tamaños. Restar $E[\text{MI}]$ permite comparar atributos con distinto número de categorías, como el continente (7) y el idioma (más de 30).

Tabla 1: AMI de las comunidades con cada atributo y modularidad de la partición.

	$k = 2$	$k = 4$
AMI continente	0,401	0,514
AMI idioma	0,169	0,313
AMI clima	0,131	0,189
Modularidad	0,439	0,485
Tamaños	18 / 54	18 / 33 / 19 / 2

Chile y países puente. Chile está en el bloque hispano, y su país más parecido es Perú (0,574), seguido de Bolivia (0,534), Paraguay (0,529) y Ecuador (0,513). Para medir qué países son puente se usó el *índice de frontera*, la fracción del peso de las aristas de un país que va hacia otras comunidades. El de Chile es 0: todos sus vecinos son hispanos, de modo que Chile está en el centro de su bloque. Los países puente son Rumania (0,66), Bulgaria (0,66), Ucrania (0,61), Emiratos (0,60) y Egipto (0,55), que reparten su afinidad entre Europa y Asia/Medio Oriente.

3.5. Diseño experimental

Experimento 1: Laplaciano no normalizado frente a normalizado (Tabla 2). Con $k = 2$ ambos dan la misma partición. Con $k = 4$, el Laplaciano no normalizado forma dos grupos de un solo país (Nigeria y Turquía), que son nodos de grado bajo cuyo corte es barato, tal como se explicó en la Pregunta 5c. En la Figura 7 se ve que su segundo vector propio también separa al bloque hispano. El normalizado entrega grupos interpretables y con mayor modularidad.

Tabla 2: Experimento 1: comparación de Laplacianos con $k = 4$.

Laplaciano	Tamaños	AMI cont.	AMI idioma	Modul.	Grupos de 1
L (no normalizado)	52 / 1 / 18 / 1	0,428	0,171	0,439	Nigeria, Turquía
L_{sym} (normalizado)	33 / 18 / 19 / 2	0,514	0,313	0,485	—




Figura 7: Segundo vector propio del Laplaciano no normalizado.

Experimento 2: quitar los éxitos globales (Tabla 3). Se eliminaron las 313 canciones que estuvieron en el Top 50 de al menos el 30 % de los países, como *Die With A Smile*, presente en el 95,8 % de ellos. Luego se repitió todo el procedimiento. La similitud mediana entre países cae de 0,056 a casi 0: los éxitos globales sostienen casi toda la similitud. El bloque hispano se mantiene, pero ahora el *eigengap* sugiere 7 grupos (Figura 8):

- Brasil y Portugal forman un bloque lusófono.

- Italia se une al bloque hispano.
- Emiratos Árabes se une a India y Pakistán.
- Marruecos queda con Europa continental.

En esta red el idioma explica bastante más (AMI de 0,31 a 0,45). Los éxitos globales esconden diferencias locales que se relacionan sobre todo con el idioma.

Tabla 3: Experimento 2: con y sin los éxitos globales.

	Todas las canciones ($k = 4$)	Sin éxitos globales ($k = 7$)
AMI continente	0,514	0,511
AMI idioma	0,313	0,450
AMI clima	0,189	0,204
Modularidad	0,485	0,474

Comunidades sin los éxitos globales ($k = 7$)




Figura 8: Comunidades al quitar los éxitos globales ($k = 7$, elegido por *eigengap*).

Experimento 3: red con pesos frente a red sin pesos (Tabla 4). Se mantuvieron exactamente las mismas aristas, porque cada país sigue conectado con sus 12 países más parecidos, pero todas pasaron a valer 1. Con $k = 2$ la partición es idéntica, de modo que el bloque hispano no depende de los pesos. Sin pesos, λ_2 sube de 0,0003 a 0,004, porque la arista débil Japón–Perú vale lo mismo que cualquier otra, y el *eigengap* deja de apoyar $k = 4$ (Figura 9a). Con $k = 4$ la partición cambia bastante (ARI = 0,55 con la partición base, donde 1 indica particiones idénticas): el mundo anglosajón se separa de Europa continental y desaparece el grupo India–Pakistán, ya que India queda con Europa continental, lo que no tiene sentido musical (Figura 9b). La modularidad baja de 0,49 a 0,44. Los pesos importan para la estructura más fina, porque evitan que las conexiones débiles cuenten igual que las fuertes.

Tabla 4: Experimento 3: red con pesos y sin pesos.

	Con pesos (base)	Sin pesos
λ_2	0,0003	0,004
k sugerido por el <i>eigengap</i>	2 y 4	2 y 3
Tamaños ($k = 4$)	18 / 33 / 19 / 2	18 / 25 / 15 / 14
AMI continente	0,514	0,503
AMI idioma	0,313	0,356
AMI clima	0,189	0,150
Modularidad	0,485	0,436



Figura 9: (a) Valores propios de L_{sym} con y sin pesos. (b) Comunidades de la red sin pesos ($k = 4$).

3.6. Limitaciones y extensiones

Limitaciones.

- Solo se observa el Top 50 de cada país.
- Spotify no opera en algunos mercados grandes, como China.
- Algunos países tienen días sin datos.
- La regla de 12 vecinos obliga a conectar a países de gusto muy local con vecinos poco parecidos (por ejemplo, Japón–Perú).
- El idioma principal es discutible en países multilingües.
- La clasificación climática es sensible en casos límite, como Chile, que queda empatado entre seco y templado.
- El grupo India–Pakistán tiene solo dos países.

Extensión propuesta. Construir una red por mes (red temporal) para estudiar si las comunidades cambian a lo largo del año, por ejemplo con los éxitos de verano de cada hemisferio. También se podrían comparar los resultados con métodos que maximizan la modularidad, como Louvain.

4. Conclusiones

1. El espectro muestra dos grandes bloques de gusto musical: el hispano (América Latina hispanohablante y España) y el resto del mundo. Para menos de 12 vecinos aparece como dos

componentes conexas (valor propio 0 doble), y con 12 vecinos como un λ_2 casi nulo. Con $k = 4$ se separan además Europa y el mundo anglosajón; Asia, Medio Oriente y Europa del Este; y el sur de Asia.

2. El continente es lo que más coincide con las comunidades, seguido por el idioma, y el clima es lo que menos las explica. El idioma explica casos que la geografía no explica: España con América Latina y Brasil aparte.
3. Los éxitos globales sostienen casi toda la similitud entre países. Al quitarlos aparece una estructura más local y ligada al idioma (bloque lusófono, Italia con el bloque hispano).
4. Chile está en el centro del bloque hispano y su país más parecido es Perú. Los países puente están entre Europa y Asia/Medio Oriente.

Los resultados ilustran lo visto en la Parte I:

- la multiplicidad del 0 cuenta las componentes;
- el signo del vector de Fiedler da la bipartición;
- el *eigengap* orienta la elección de k ;
- la normalización evita grupos de un solo nodo.

Las principales limitaciones son la cobertura de los datos y lo discutibles que son los atributos externos.

Referencias

- *Top Spotify Songs in 73 Countries (Daily Updated)*. Kaggle, licencia ODC-By. <https://www.kaggle.com/datasets/asaniczka/top-spotify-songs-in-73-countries-daily-updated>
- Mapas Köppen-Geiger 1991–2020, resolución 1 km. Figshare, licencia CC0. <https://figshare.com/articles/dataset/21937571>
- GeoNames, *cities15000*. Licencia CC BY 4.0. <https://download.geonames.org/export/ump/>
- WorldClim 2.1, temperatura media anual. <https://www.worldclim.org>
- Natural Earth, límites de países 1:50m (dominio público). <https://www.naturalearthdata.com>
- Documentación de NumPy, pandas, scikit-learn, NetworkX y Matplotlib: <https://numpy.org>, <https://pandas.pydata.org>, <https://scikit-learn.org>, <https://networkx.org>, <https://matplotlib.org>

Declaración de uso de Inteligencia Artificial

Modelo utilizado.

- Claude. Claude Opus 5.5.

- Chat GPT. 6 Luna

Modalidad de uso.

- Claude: Aplicación descargada en el laptop localmente.
- Luna: Aplicación descargada en el laptop localmente.

Uso de las respuestas. Los prompts se agrupan según las etapas del trabajo. Para cada conjunto se indica qué se le pidió a la herramienta y en qué parte del informe o del código se usaron sus respuestas.

1. **Comprensión del enunciado y elección de los datos.** Se pidió explicar los requisitos del trabajo y los criterios para elegir una base de datos y una pregunta de análisis, proponer bases de datos posibles. *Uso:* explicación de conceptos y apoyo a la elección de la base de datos, (Sección 3.1). La base, el enfoque (red de países) y las preguntas fueron elegidos por el equipo.
2. **Decisiones metodológicas.** Se pidió aclarar la estructura de los datos (el Top 50 cambia cada día), excluir el Top 50 Global, usar todo el período y definir el clima de cada país según dónde vive su población, con la categoría “Variado” solo para países imposibles de encasillar. *Uso:* decisiones de preprocesamiento, medida de similitud y criterio de clima (Sección 3.2). Los criterios del clima fueron definidos por el equipo.
3. **Código y visualizaciones.** Se pidió desarrollar el notebook en Python: descarga y limpieza de los datos, cálculo del clima, construcción de la red, implementación del clustering espectral, experimentos y gráficos (componentes conexas, espectro y *eigengap*, vector de Fiedler, mapas de comunidades, representación espectral y red). *Uso:* generación, corrección y depuración de código, análisis exploratorio y preparación de las Figuras 1 a 9 (Secciones 3.3 a 3.5).
4. **Redacción del informe.** Se pidió ayuda en ciertas secciones para mejorar la redacción y además creación de formulas en Latex, junto con los subtítulos a las imágenes y las tablas

Prompts utilizados.

1. “Inspecciona el CSV de Spotify y resume sus columnas, fechas, países, canciones, valores faltantes y duplicados.”
2. “Limpia los datos usando todo el período indicado, excluye el Top 50 Global y elimina duplicados por país, fecha y canción.”
3. “Prepara los atributos de cada país: continente, idioma y clima. Explica cómo se asigna el clima usando las ciudades y su población.”
4. “Construye una matriz país-canción donde cada valor indique cuántos días estuvo esa canción en el Top 50 del país.”
5. “Calcula la similitud coseno entre los perfiles musicales de los países y revisa que la matriz sea simétrica y tenga diagonal cero.”
6. “Construye redes de vecinos cercanos para distintos valores de k , encuentra el menor k que conecta la red y guarda el gráfico.”
7. “Calcula las matrices A , D , L y L_{sym} . Verifica numéricamente las propiedades del Laplaciano.”

8. "Calcula los valores propios de L_{sym} , identifica los principales eigengaps y guarda el gráfico."
9. "Obtén el vector de Fiedler, úsalo para separar los dos bloques principales y guarda el gráfico."
10. "Implementa clustering espectral para $k=2$ y $k=4$ usando L_{sym} y k-means. Presenta las comunidades y los países que contiene cada una."
11. "Dibuja el mapa mundial de las comunidades para $k=4$ y guárdalo como fig04_mapa_k4.png."
12. "Proyecta la representación espectral a dos dimensiones, colorea los países por comunidad y guarda el gráfico."
13. "Dibuja la red de países coloreada por comunidad, destaca las aristas entre los dos bloques principales y guarda el grafico."
14. "Compara las comunidades con continente, idioma y clima usando AMI y modularidad. Dime qué atributos coinciden más con los grupos."
15. "Compara el Laplaciano normalizado y el no normalizado para $k=2$ y $k=4$. Señala si alguno genera grupos de un solo país y guardalo en un grafico"
16. "Elimina las canciones presentes en al menos el 30 % de los países, reconstruye la red y el clustering, y guarda el nuevo mapa."
17. "Analiza Chile: calcula sus países más parecidos, su comunidad y los países puente entre grupos. Resume los resultados en una tabla."